字符串算法 part 31

赖金霖2

清华大学 计算机科学与技术系

Aug 11, 2019

¹本文件可在这里找到: https://github.com/lll6924/public_slides

²邮箱: laijl16@mails.tsinghua.edu.cn

给定一个英语句子,统计若干给定单词的出现次数

样例输入

He will go with her, but he will not stay for long. he wi

样例输出

3

规定

- ▶ 不区分大小写
- ▶ 单词可以出现在另一个单词里
- ▶ 单词可以相交(如 aa 在 aaa 里出现了两次)

和上一部分相比,我们只增加了寻找的单词的数量

- ▶ 我们已经熟练掌握了 KMP 算法,这种问题当然可以直接做
- ▶ 对每个单词,首先计算 B 数组,再用 KMP 算法统计句子里 的出现次数
- ▶ 时间复杂度 O(NM+L), 其中 N 为句子长度, M 为单词个数, L 为单词长度之和
- ▶ 复杂度瓶颈在于,对不同的单词,都需要重新遍历一遍句子
- ▶ 如果有一种算法能通过一次遍历算出所有单词的出现次数, 复杂度就是 O(N+L)

▶ 解决这个问题的通用算法叫做自动 AC 机 AC 自动机



Alfred V. Aho



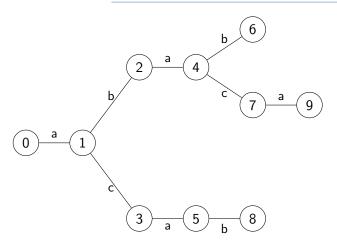
Margaret J.Corasick

据经验, AC 自动机会比 KMP 算法好理解

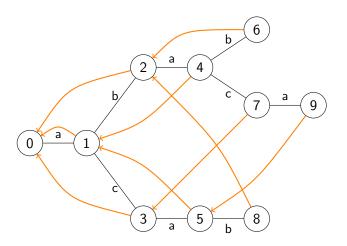
- ▶ 我们以一个例子出发,介绍 AC 自动机的思路
- ▶ 假设我们要在 ababacabaa 里找 abab、abaca 和 acab
- ▶ 首先,我们要分别为 abab、abaca 和 acab 建立 B 数组
- ▶ 你发现了什么问题吗?

- ▶ 我们以一个例子出发,介绍 AC 自动机的思路
- ▶ 假设我们要在 ababacabaa 里找 abab、abaca 和 acab
- ▶ 首先,我们要分别为 abab、abaca 和 acab 建立 B 数组
- ▶ 你发现了什么问题吗?
- ▶ 1. abab 和 abaca 的前三个字符相同,所以 B 数组的数值也 相同
- ▶ 2. 更进一步,如果我们匹配 abaca 的最后一个字符失败了, 当前匹配的字串是 abac,是否可以转到匹配 acab?
- ▶ 我们能利用 Trie 树的结构来加速计算吗?

- ▶ 我们以一个例子出发,介绍 AC 自动机的思路
- ▶ 假设我们要在 ababacabaa 里找 abab、abaca 和 acab
- ▶ 首先,我们要分别为 abab、abaca 和 acab 建立 B 数组
- ▶ 你发现了什么问题吗?
- ▶ 1. abab 和 abaca 的前三个字符相同,所以 B 数组的数值也 相同
- ▶ 2. 更进一步,如果我们匹配 abaca 的最后一个字符失败了, 当前匹配的字串是 abac,是否可以转到匹配 acab?
- ▶ 我们能利用 Trie 树的结构来加速计算吗?
- ▶ AC 自动机正是这样的结构



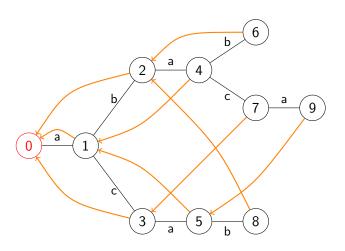
将三个字符串转成 Trie 树如上图所示。和 KMP 算法类似,我们可以计算 Trie 树的"B 数组"!

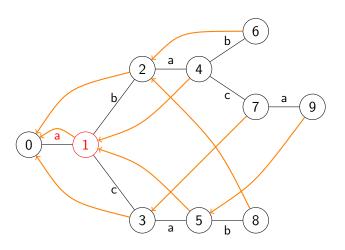


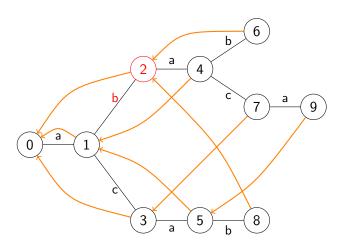
我们需要计算如上的关系,其中橙色边被称为失配边

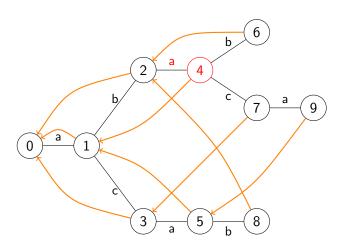
- ▶ 与 KMP 算法类似,我们可以设计失配边的计算算法
- ▶ 我们设 B[i] 表示 i 的失配边指向的结点,pre[i] 表示 i 在 Trie 上的父结点
- ▶ B[i] 可以通过 B[pre[i]] 推出,怎么做?

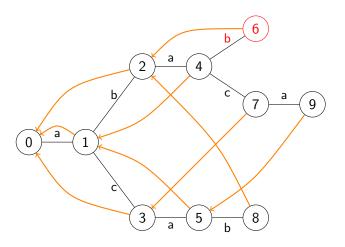
- ▶ 与 KMP 算法类似,我们可以设计失配边的计算算法
- ▶ 我们设 B[i] 表示 i 的失配边指向的结点,pre[i] 表示 i 在 Trie 上的父结点
- ▶ B[i] 可以通过 B[pre[i]] 推出,怎么做?
- ▶ 设从 pre[i] 到 i 的字符为 c, 那么如果 c 是 B[pre[i]] 的后代 边, B[i] 就是 B[pre[i]].son[c]
- ▶ 如果 c 不是 B[pre[i]] 的后代边,我们接着考虑 B[B[pre[i]]], 看 c 是否是 B[B[pre[i]]] 的后代边,此后的分析都是类似的
- ▶ 计算出失配边后,我们可以看看这个系统是如何匹配 ababacabaa 的



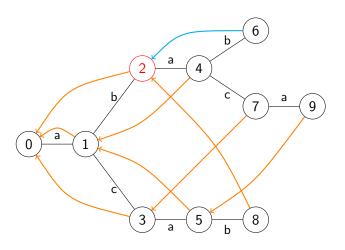




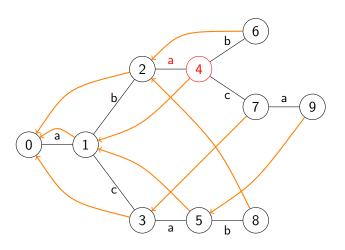


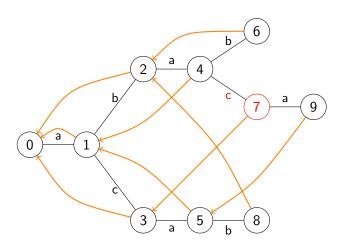


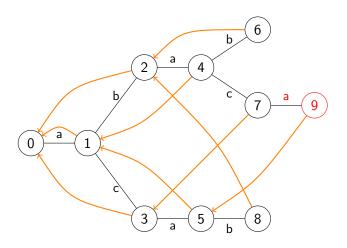
ababacabaa, 匹配到一个单词, 走一步失配边



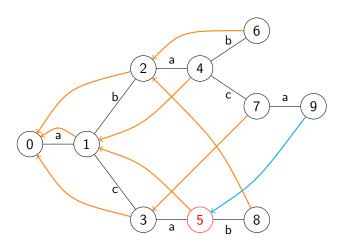
ababacabaa,继续匹配下一个字母



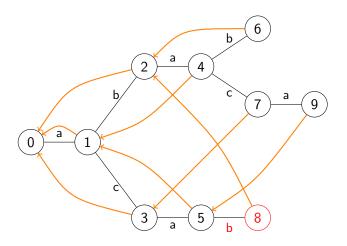




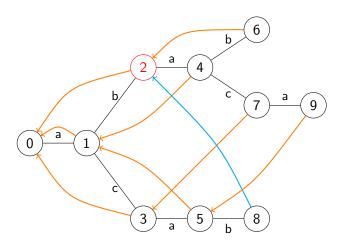
ababacabaa,匹配到一个单词,走一步失配边



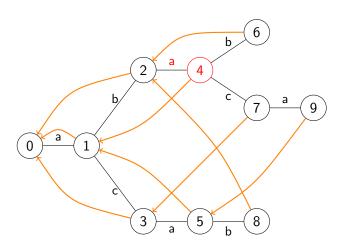
ababacabaa,匹配下一个字母

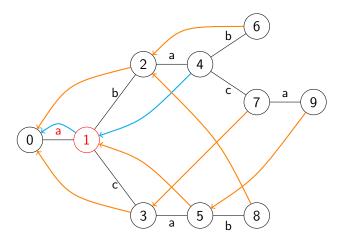


ababacabaa, 匹配到单词, 走一步失配边



ababacabaa,继续匹配下一个字母





ababacabaa, 4 号结点之后没有匹配 a 字母的边,沿失配边往回找,直到 0 号节点,才有匹配 a 字母的边

- ► 在 Trie 树上计算失配边后,我们可以以 O(N) 的复杂度找到每个匹配的字符串
- ▶ 你发现什么问题了吗?

- 在 Trie 树上计算失配边后,我们可以以 O(N) 的复杂度找到 每个匹配的字符串
- ▶ 你发现什么问题了吗?
- ▶ 这个算法仍然有瑕疵!
- ▶ 在上页 AC 自动机的基础上,假如我们还要找 ab 出现的次数,算法会怎么算?

- 在 Trie 树上计算失配边后,我们可以以 O(N) 的复杂度找到 每个匹配的字符串
- ▶ 你发现什么问题了吗?
- ▶ 这个算法仍然有瑕疵!
- ▶ 在上页 AC 自动机的基础上,假如我们还要找 ab 出现的次数,算法会怎么算?
- ▶ 假如我们的输入就是 abab,算法会先走到 2 号结点,找到 一个 ab,再走到 6 号节点,找到一个 abab
- ▶ 第二个 ab 没有被直接找到!
- ▶ 更糟糕的是,如果输入是 acab,最后会走到 8 号结点,一 个 ab 都没找到

- 在 Trie 树上计算失配边后,我们可以以 O(N) 的复杂度找到 每个匹配的字符串
- ▶ 你发现什么问题了吗?
- ▶ 这个算法仍然有瑕疵!
- ▶ 在上页 AC 自动机的基础上,假如我们还要找 ab 出现的次数,算法会怎么算?
- ▶ 假如我们的输入就是 abab,算法会先走到 2 号结点,找到 一个 ab,再走到 6 号节点,找到一个 abab
- ▶ 第二个 ab 没有被直接找到!
- ▶ 更糟糕的是,如果输入是 acab,最后会走到 8 号结点,一 个 ab 都没找到
- ▶ 从失配边的角度看,失配边也形成了一棵树
- ▶ ab 的出现次数,其实是表示 ab 的结点在失配边树上的后代 的访问次数之和!

- ► 有许多 OI 选手反映,学完 AC 自动机后才理解 KMP 算法, 希望这部分内容能用来加深大家对 KMP 算法的理解
- ▶ 自动机有一套完整的理论,AC 自动机是其中最经典的模型 之一
- ▶ 如果对相关理论在 OI 界的应用感兴趣,可以自学后缀自动机、回文自动机
- ▶ 在计算机科学领域,自动机理论是编译器的基础
- ▶ 因为这部分内容超出 NOIP 范围,所以不安排例题讲解,大 家可以自行刷模板题

给定一个字符串,求以每个字符为中心的最长回文串长度

样例输入

abacabadaba

样例输出

13171317131

给定一个字符串,求以每个字符为中心的最长回文串长度

样例输入

abacabadaba

样例输出

13171317131

- ▶ 以字符为中心,只考虑了长度为奇数的回文串
- ▶ 长度为偶数的回文串,中心是两个相同的字符
- ▶ 如果我们遇到需要考虑偶数回文串的情况,要怎么考虑?

给定一个字符串,求以每个字符为中心的最长回文串长度

样例输入

abacabadaba

样例输出

13171317131

- ▶ 以字符为中心,只考虑了长度为奇数的回文串
- ▶ 长度为偶数的回文串,中心是两个相同的字符
- ▶ 如果我们遇到需要考虑偶数回文串的情况,要怎么考虑?
- ▶ 把偶数回文串,转化为奇数回文串
- ▶ 做法是在相邻字符之间增加其他字符 #
- ▶ 以 # 为中心的回文串代表了偶数回文串
- ▶ 所以我们只需要考虑以字符为中心的奇数回文串问题

暴力算法

- ▶ 枚举每个字符,不断比较左右两边的字符,求得答案
- ▶ 最坏时间复杂度 O(N²)
- ▶ 平均时间复杂度是多少?

暴力算法

- ▶ 枚举每个字符,不断比较左右两边的字符,求得答案
- ▶ 最坏时间复杂度 O(N²)
- ▶ 平均时间复杂度是多少?
- ▶ 平均而言,以每个字符为中心,只会进行 ⅔ 次比较
- ▶ 平均时间复杂度 O(N)

暴力算法

- ▶ 枚举每个字符,不断比较左右两边的字符,求得答案
- ▶ 最坏时间复杂度 O(N²)
- ▶ 平均时间复杂度是多少?
- ▶ 平均而言,以每个字符为中心,只会进行 ²⁶/₂₅ 次比较
- ▶ 平均时间复杂度 O(N)
- ▶ 很显然,我们可以用二分 + 字符串 Hash 优化这一算法,把 最坏复杂度降低到 O(NlogN),把平均复杂度上升到 O(NlogN)
- ▶ 这些暴力算法没有充分利用不同中心的回文串之间的关系

- ▶ Manacher 算法的作者叫做 Manacher, 关于他的资料很少
- Manacher 算法是一个以 O(N) 的时空复杂度计算以每个字符为中心的最长回文串的算法,俗称马拉车
- 需要注意的是,Manacher 算法只是处理回文串问题的思路 之一,有些问题可以使用字符串 Hash,而在更难的问题里 还有回文自动机等工具

- ▶ Manacher 算法的作者叫做 Manacher,关于他的资料很少
- Manacher 算法是一个以 O(N) 的时空复杂度计算以每个字符为中心的最长回文串的算法,俗称马拉车
- 需要注意的是,Manacher 算法只是处理回文串问题的思路 之一,有些问题可以使用字符串 Hash,而在更难的问题里 还有回文自动机等工具
- ▶ 设以 i 字符为中心的最长回文串长度为 2*H[i]+1, H[i] 的意 义是 i 字符往两边匹配的字符数量
- ► Manacher 算法的思路是,在计算 H[i] 时,用 0 ≤ j < i 中 j+H[j] 最大的回文串,即当前最右的回文串来节省计算

- ▶ 共有两种情况
- ▶ 1、如果 i>j+H[j],直接以 i 为中心暴力计算,计算完后 i+H[i] 成为最右的回文串
- ▶ 2、如果 i<=j+H[j],我们可以用下图来理解



- ▶ 我们再分两种情况
- ▶ 如果 i+H[2*j-i]<j+H[j],即不存在橙色部分,且绿色部分严格在 j 的回文串内,那么 H[i]=H[2*j-i]</p>
- 如果 i+H[2*j-i]≥j+H[j],则 H[i] 至少为 j+H[j]-i,可以在这个基础上,暴力求解
- ▶ 算出的 i+H[i] 可以更新最右的回文串
- ▶ 这个算法的复杂度怎么分析?

- ▶ 我们再分两种情况
- ▶ 如果 i+H[2*j-i]<j+H[j],即不存在橙色部分,且绿色部分严格在 j 的回文串内,那么 H[i]=H[2*j-i]</p>
- ▶ 如果 i+H[2*j-i]≥j+H[j],则 H[i] 至少为 j+H[j]-i,可以在这个基础上,暴力求解
- ▶ 算出的 i+H[i] 可以更新最右的回文串
- ▶ 这个算法的复杂度怎么分析?
- ▶ 只考虑最右的字符串,我们发现,每当我们暴力求解 H[i] 时,最右的字符串都相应地往右移动
- ▶ 因为最右的字符串最多移动 N 次,所以暴力的执行次数最 多为 N 次
- ▶ 总时间复杂度 O(N)

```
int i=-1, right =-1;
for (int i = 0; i < n; i + +){
     if (i>right)H[i]=0;
    else if (i+H[2*i-i] < right)H[i]=H[2*i-i];
    else H[i] = right - i;
    while (i-H[i]>0\&\&i+H[i]+1< n
             \&\&x[i+H[i]+1]==x[i-H[i]-1])
         H[i]++;
     if ( i+H[i]> right ){
         i=i:
         right=i+H[i];
```

计算代码如上所示

例题讲解-BZOJ2160 拉拉队排练

题目大意:给一个长度为 n 的字符串和 k,求子串中前 k 长的奇数回文串的长度之积。答案模 19930726,不够 k 个答案为-1

 $n \le 1,000,000$ $k \le 1,000,000,000,000$

样例输入

5 3

ababa

样例输出

45

题目大意:给一个长度为 n 的字符串和 k,求子串中前 k 长的奇数回文串的长度之积。答案模 19930726,不够 k 个答案为-1

 $n \le 1,000,000$ $k \le 1,000,000,000,000$

样例输入

5 3 ababa

样例输出

45

▶ 机智的同学可能已经发现了,这题的重点不是 Manacher 算 法本身

- ► 很显然,我们能先使用 Manacher 算法算出以每个字符为中 心的最长回文串
- ▶ 以 i 为中心的回文串有 [i H[i], i + H[i]],
 [i H[i] + 1, i + H[i] 1], [i H[i] + 2, i + H[i] 2],..., [i, i],
 长度分别为 2H[i] + 1, 2H[i] 1, 2H[i] 3, ..., 1
- ▶ 如果我们能有一种高效的方法,算出所有 i 的所有区间中前 k 长区间长度之积,就能解决这个问题了

- ► 很显然,我们能先使用 Manacher 算法算出以每个字符为中 心的最长回文串
- ▶ 以 i 为中心的回文串有 [i H[i], i + H[i]],
 [i H[i] + 1, i + H[i] 1], [i H[i] + 2, i + H[i] 2],..., [i, i],
 长度分别为 2H[i] + 1, 2H[i] 1, 2H[i] 3, ..., 1
- 如果我们能有一种高效的方法,算出所有 i 的所有区间中前 k 长区间长度之积,就能解决这个问题了
- 解法一:二分第 k 长区间长度,每次遍历计算数量,最后遍历 H 数组计算答案,以每个字符为中心的答案是一个双阶乘除以双阶乘的形式,需要计算奇数的前缀积与奇数逆元的前缀积,时间复杂度 O(NlogK)

- ► 很显然,我们能先使用 Manacher 算法算出以每个字符为中 心的最长回文串
- ▶ 以 i 为中心的回文串有 [i H[i], i + H[i]],
 [i H[i] + 1, i + H[i] 1], [i H[i] + 2, i + H[i] 2],..., [i, i],
 长度分别为 2H[i] + 1, 2H[i] 1, 2H[i] 3, ..., 1
- ▶ 如果我们能有一种高效的方法,算出所有 i 的所有区间中前 k 长区间长度之积,就能解决这个问题了
- 解法一:二分第 k 长区间长度,每次遍历计算数量,最后遍历 H 数组计算答案,以每个字符为中心的答案是一个双阶乘除以双阶乘的形式,需要计算奇数的前缀积与奇数逆元的前缀积,时间复杂度 O(NlogK)
- ightharpoonup 解法二:统计各长度最长回文串的数量,求一个后缀和,变成各长度回文串数量,再贪心计算即可,使用快速幂计算,时间复杂度 $O(Nlog \frac{N}{N})$

- ► 很显然,我们能先使用 Manacher 算法算出以每个字符为中 心的最长回文串
- ▶ 以 i 为中心的回文串有 [i H[i], i + H[i]],
 [i H[i] + 1, i + H[i] 1], [i H[i] + 2, i + H[i] 2],..., [i, i],
 长度分别为 2H[i] + 1, 2H[i] 1, 2H[i] 3, ..., 1
- ▶ 如果我们能有一种高效的方法,算出所有 i 的所有区间中前 k 长区间长度之积,就能解决这个问题了
- 解法一:二分第 k 长区间长度,每次遍历计算数量,最后遍历 H 数组计算答案,以每个字符为中心的答案是一个双阶乘除以双阶乘的形式,需要计算奇数的前缀积与奇数逆元的前缀积,时间复杂度 O(NlogK)
- ightharpoonup 解法二:统计各长度最长回文串的数量,求一个后缀和,变成各长度回文串数量,再贪心计算即可,使用快速幂计算,时间复杂度 $O(Nlog \frac{N}{N})$
- ► 解法三:结合解法一和解法二,使用解法二的思路求出第 k 长区间长度,然后使用解法一的方法遍历 H 数组计算答案, 时间复杂度 O(N)

▶ 题目大意:设字符串 w 的反转为 w^R,定义双倍回文串为形 如 ww^R ww^R 的字符串,对给定字符串,求最长双倍回文子 串的长度

样例输入

16

ggabaabaabaaball

样例输出

12

对样例输入,最长的双倍回文子串是 abaabaabaaba

- ▶ 注意到,本题只用考虑偶数回文串
- ▶ 设 H[i] 表示以第 i 个字符和第 i+1 个字符为中心的最长回 文串半径(长度/2),问题能转化成什么样?

- ▶ 注意到,本题只用考虑偶数回文串
- ▶ 设 H[i] 表示以第 i 个字符和第 i+1 个字符为中心的最长回 文串半径(长度/2),问题能转化成什么样?
- ▶ 双倍回文串可以用两个字符 i, j 确定, 其中 i 是双倍回文串中心, j 是左半回文串中心; 对任给的 i 和 j, 需要满足什么条件, 才是双倍回文串?

- ▶ 注意到,本题只用考虑偶数回文串
- ▶ 设 H[i] 表示以第 i 个字符和第 i+1 个字符为中心的最长回 文串半径(长度/2),问题能转化成什么样?
- 双倍回文串可以用两个字符 i, j确定,其中 i 是双倍回文串中心,j是左半回文串中心;对任给的 i 和 j,需要满足什么条件,才是双倍回文串?
- ▶ 条件是 j+H[j]+1>=i 且 j>=i-H[i]/2, 固定 i 时, j 越小, 双 倍回文串越长

- ▶ 注意到,本题只用考虑偶数回文串
- ▶ 设 H[i] 表示以第 i 个字符和第 i+1 个字符为中心的最长回 文串半径(长度/2),问题能转化成什么样?
- 双倍回文串可以用两个字符 i, j确定,其中 i 是双倍回文串中心,j是左半回文串中心;对任给的 i 和 j,需要满足什么条件,才是双倍回文串?
- ▶ 条件是 j+H[j]+1>=i 且 j>=i-H[i]/2, 固定 i 时, j 越小, 双 倍回文串越长
- ▶ 算法一:将 j+H[j]+1 排序,循环 i,维护存储 j 的 set,确保当遍历到 i 时,所有满足 j+H[j]+1>=i 的 j 都在 set 中,我们只需要找最小的满足 j>=i-H[i]/2 的 j 即可,时间复杂度 O(NlogN)

- ▶ 注意到,本题只用考虑偶数回文串
- ▶ 设 H[i] 表示以第 i 个字符和第 i+1 个字符为中心的最长回 文串半径(长度/2),问题能转化成什么样?
- ▶ 双倍回文串可以用两个字符 i, j确定,其中 i是双倍回文串中心,j是左半回文串中心;对任给的 i和 j,需要满足什么条件,才是双倍回文串?
- ▶ 条件是 j+H[j]+1>=i 且 j>=i-H[i]/2, 固定 i 时, j 越小, 双 倍回文串越长
- ▶ 算法一:将 j+H[j]+1 排序,循环 i,维护存储 j 的 set,确保当遍历到 i 时,所有满足 j+H[j]+1>=i 的 j 都在 set 中,我们只需要找最小的满足 j>=i-H[i]/2 的 j 即可,时间复杂度 O(NlogN)
- ▶ 算法二:固定 j 时, i 越大,双倍回文串越长,我们也可以 反过来设计类似算法一的做法

问题:给出一个长度为 n 的字符串 S,有 q 组询问,每组询问给出一个回文串 a,求 a 是否是 S 的子串

- ▶ 一个直接的想法是,枚举 a 在 S 中的位置,采用字符串 Hash 的方法比较,时间复杂度为 O(nq)
- ▶ 如何利用回文串的性质?

问题:给出一个长度为 n 的字符串 S,有 q 组询问,每组询问给出一个回文串 a,求 a 是否是 S 的子串

- ▶ 一个直接的想法是,枚举 a 在 S 中的位置,采用字符串 Hash 的方法比较,时间复杂度为 O(nq)
- ▶ 如何利用回文串的性质?
- ▶ 一个直接的想法是,用 Manacher 算法预处理以每个字符 (包括 #)为中心的最长回文串长度,然后把这个最长回文 串的后半部分插入 Trie 树中
- ▶ 在查询时,只要把询问的后半拿出,在 Trie 树上查询即可
- ▶ 时间复杂度 O(n² + q|a|), 还能优化吗

- ▶ 观察到,这样的 Trie 树分为两块——奇数回文串部分和偶数回文串部分,整个树被称为回文树
- ▶ 统计回文树中的结点数 m, 发现总是 m ≤ n, 这是有什么性 质吗?
- ▶ 回文树中的结点数等于互不相同的回文子串数量

- ▶ 观察到,这样的 Trie 树分为两块——奇数回文串部分和偶数回文串部分,整个树被称为回文树
- ▶ 统计回文树中的结点数 m, 发现总是 m ≤ n, 这是有什么性 质吗?
- ▶ 回文树中的结点数等于互不相同的回文子串数量
- ▶ 对于一个字符串 S,在 S 之后增加一个字符 c,它的回文树最多增加一个字符,即最多增加一个不同的回文子串
- ▶ 增加的回文子串一定以 c 结尾,考虑所有以 c 为结尾的回文子串,设其中最长的为 S_0 ,其他为 S_1 , S_2 , ...
- \triangleright S_1 是 S_0 的后缀;而因为 S_0 是回文串,所以 S_1 还是 S_0 的前缀。所以除 S_0 外,其他回文串都一定在回文树里出现了

- ▶ 在 Manacher 算法的计算过程中,回文树就能构建出来
- ▶ 和倍增类似,维护回文树每个结点的第 2ⁱ 个祖先,那么可以 O(logn) 地找到每个结点的第 k 个祖先
- ▶ 同时,维护以每个字符为中点的最长回文串在回文树中的位置
- ► Manacher 计算 H[i] 时,可能从左方对称过来,之后可能会 往两边扩展

- ▶ 在 Manacher 算法的计算过程中,回文树就能构建出来
- 和倍增类似,维护回文树每个结点的第 2ⁱ 个祖先,那么可以 O(logn) 地找到每个结点的第 k 个祖先
- ▶ 同时,维护以每个字符为中点的最长回文串在回文树中的位置
- Manacher 计算 H[i] 时,可能从左方对称过来,之后可能会 往两边扩展
- 从左方对称过来时,一定是左边的最长回文串的"同心子串","同心子串"在回文树中的位置可以用倍增算出,设为以i为中心的最长回文串所在位置
- ▶ 在往两边扩展时,需要从当前最长回文串所在位置出发,往回文树的下方走,过程中可能要新建结点
- ▶ 时间和空间复杂度都是 O(nlogn)
- ▶ 回文树还有基于回文自动机的构建做法,复杂度为 O(n), 感兴趣的同学可以自行学习

字符串算法总结

- ▶ 几乎所有字符串算法,都有字符串 Hash 算法的替代品
- ▶ 几乎所有字符串算法,都需要考虑最坏复杂度
- ▶ AC 自动机是 Trie 树和 KMP 算法的结合体
- ▶ Manacher 算法、回文树是处理回文串问题的基础算法
- ▶ 虽然字符串算法在 NOIP 涉及较少,但是字符串算法中的技 巧、思想是通用的

Thanks for listening

Any Questions?